

Introduktion till datamaterial till INL1

Ni har fått tillgång till ett simulerat datamaterial som beskriver ett stort antal företag. Datamaterialet innehåller både prediktorer (olika egenskaper hos företagen) och två målvariabler. Variablerna i datamaterialet är anonymiserade. Det innebär att variablernas namn inte avslöjar vad de representerar.

Ni ska:

- Förbereda datamaterialet. Datamaterialet är inte färdigt för analys. Innan ni börjar modellera behöver ni själva undersöka datamaterialet och fatta relevanta beslut om hur den ska förberedas. Det kan exempelvis innebära att ni:
 - identifierar och hanterar saknade värden,
 - identifierar orimliga eller avvikande observationer,
 - undersöker om vissa variabler behöver transformeras,
 - bedömer om någon variabel bör tas bort från analysen.
- Utforska variablerna genom att undersöka deras fördelningar, skalor och andra relevanta egenskaper.
- Tolka och namnge variablerna utifrån vad ni bedömer att de rimligen skulle kunna representera.
- Skapa ett företagsfall där era tolkningar av variablerna bildar ett sammanhängande och trovärdigt scenario.
- Undersöka sambanden mellan prediktorerna och målvariablerna.
- Utveckla två modeller – en för mönsterigenkänning och en för prediktion – som skulle kunna användas inom ramen för ert företagsfall. Ni finner mer instruktioner vad gäller INL1 på Canvas.

Era val ska vara motiverade utifrån både datamaterialet och det företagsfall ni har skapat. Det finns därför inte nödvändigtvis en enda korrekt tolkning av variablerna eller ett enda korrekt sätt att förbereda datamaterialet.

Era tolkningar behöver inte motsvara variablernas ursprungliga betydelse. Det viktiga är att:

- tolkningen är förenlig med variabelns datatyp, värden och fördelning,
- variablerna tillsammans bildar ett logiskt och sammanhängande företagsfall,
- målvariablerna representerar utfall som är relevanta för företaget att förstå eller förutsäga,
- ni kan motivera era val.

Beskrivning av datamaterialet

Datamaterialet är simulerat och innehåller information om ett stort antal företag. Variablernas ursprungliga betydelse har anonymiserats. De benämns därför Prediktor1–Prediktor9 samt Målvariabel1–Målvariabel2.

Er uppgift är att utifrån beskrivningarna nedan ge variablerna en rimlig betydelse och nya namn och använda dessa för att skapa ett sammanhängande företagsfall.

Det finns inget facit för exakt vad variablerna måste representera. Samma statistiska variabel kan ofta ges flera rimliga tolkningar. Det viktiga är att er tolkning passar variabelns egenskaper och att variablerna tillsammans bildar ett trovärdigt företagsfall.

Målvariabler

- **Målvariabel1:** En kontinuerlig numerisk variabel som endast antar positiva värden. De flesta observationerna ligger kring ett visst värde, medan mycket låga och mycket höga värden är mindre vanliga. Variabeln passar för något som mäts i en viss mängd och som inte kan vara negativt. Exempel på möjliga utfall är försäljning, intäkter, kostnader, investeringar eller produktion.
- **Målvariabel2:** En binär variabel som endast antar värdena 0 och 1. Variabeln passar därför för ett utfall där något antingen inträffar eller inte inträffar. Exempel på möjliga typer av utfall: expansion/ingen expansion, lyckat/misslyckat projekt, kundförlust/ingen kundförlust eller investering/ingen investering.

Övriga variabler

- **ID:** Ett unikt nummer för varje observation. Variabeln används endast för att identifiera observationerna och har ingen innehållsmässig betydelse. Exempelvis kan det representera ett företag.
- **Prediktor1:** En binär variabel som endast antar värdena 0 och 1. Variabeln kan representera en egenskap eller aktivitet som ett företag antingen har eller inte har. Exempel: deltagande i en aktivitet, användning av ett visst system, förekomst av en policy eller genomförande av en åtgärd.
- **Prediktor2:** En kontinuerlig numerisk variabel med värden mellan 0 och 100. Variabeln kan tolkas som ett index eller ett standardiserat mått där högre värden representerar en högre nivå av någon egenskap. Exempel: konkurrens, kundnöjdhet, digitalisering, marknadspotential eller organisatorisk mognad.
- **Prediktor3:** En numerisk variabel som huvudsakligen består av heltal och som normalt förväntas ligga mellan ungefär 18 och 75. De flesta observationerna är

koncentrerade kring 40. Variabeln passar för något som mäts i hela enheter och har ett naturligt begränsat intervall. Exempel: erfarenhet, ålder, antal anställda inom en viss funktion eller något annat mått som rimligen ligger inom detta intervall.

- **Prediktor4:** En diskret numerisk variabel som endast antar icke-negativa heltalsvärden. De flesta observationerna ligger relativt nära noll, ofta mellan 0 och 15, medan ett mindre antal observationer har högre värden. Variabeln passar därför särskilt bra för något som räknas. Exempel: antal nya kunder, order, reklamationer, projekt, incidenter eller genomförda aktiviteter.
- **Prediktor5:** En kontinuerlig numerisk variabel som innehåller både positiva och negativa värden och är ungefär centrerad kring noll. Variabeln passar för ett mått där både positiva och negativa avvikelser är meningsfulla. Exempel: förändring jämfört med föregående period, avvikelse från budget, skillnad mot ett branschgenomsnitt eller ett internt index.
- **Prediktor6:** En kontinuerlig numerisk variabel som normalt förväntas vara positiv. De flesta observationerna ligger kring 100, medan ett mindre antal observationer har betydligt högre värden. Fördelningen är därför något högerskev. Variabeln passar för ett mått som inte kan vara negativt och där ett mindre antal företag kan ha betydligt högre värden än övriga. Exempel: kostnader, investeringar, försäljning, antal arbetade timmar eller resursanvändning.
- **Prediktor7:** En kontinuerlig numerisk variabel som normalt förväntas vara positiv. De flesta observationerna ligger på relativt låga eller måttliga nivåer, medan ett mindre antal företag har betydligt högre värden. Fördelningen är därför högerskev. Variabeln kan representera något där låga eller måttliga nivåer är vanliga men där vissa företag kan ha mycket höga nivåer. Exempel: tidsåtgång, väntetid, kostnader, arbetsbelastning eller resursförbrukning.
- **Prediktor8:** En kategorisk variabel med tre kategorier: KategoriA, KategoriB, KategoriC. Kategorierna har ingen naturlig rangordning. Variabeln passar därför för att dela in företagen i tre olika grupper. Exempel: marknadssegment, bransch, geografisk region, affärsmodell eller kundtyp.
- **Prediktor9:** En kategorisk variabel med tre kategorier: KategoriA, KategoriB, KategoriC. Till skillnad från Prediktor8 kan kategorierna tolkas som att de har en naturlig ordning, från lägre till högre nivå. Exempel: låg/medel/hög risk, låg/medel/hög komplexitet, liten/medel/stor marknad eller låg/medel/hög strategisk prioritet.